

Organización de Datos / Ciencia de Datos

Trabajo Práctico - Primera Entrega

El trabajo práctico de la materia constará de dos entregas:

TP1: Pandas, Spark y Visu

TP2: Machine Learning

A diferencia de otros cuatrimestres, la participación en los trabajos prácticos será opcional, y los mismos asignarán hasta 1 punto adicional por entrega a sumarse a la nota de cursada (en el caso del TP1) o del examen por promoción (en el caso del TP2, habiendo aprobado el promocional).

Para anotarse y realizar los TPs deben completar el siguiente [form](#).

Queremos destacar que más allá de la no obligatoriedad del mismo, la cátedra considera altamente recomendable realizarlo ya que dará práctica y herramientas que resultarán muy valiosas a la hora de rendir los exámenes parciales.

Metodología

- El desarrollo del trabajo práctico es opcional.
- Cada alumno contará con un ayudante asignado al que podrá hacer consultas específicas sobre su trabajo.
- Para cualquier duda de la solución que están pensando, pueden pedir ayuda por Slack (sin publicar su idea), y el primer ayudante disponible intentará responderles.
- Existirá un canal de consultas general en Slack para dudas que puedan ser respondidas por cualquier miembro del equipo docente o incluso por otros alumnos.

Para la primera entrega, los alumnos deberán elegir un dataset, realizar el análisis exploratorio y una serie de consultas, que deberán ser presentadas a la cátedra.

La entrega deberá constar de:

- Análisis exploratorio de los datos propuestos

- 5 consultas resueltas en Pandas.
- 5 consultas resueltas en Spark.
- 4 visualizaciones de datos, 3 de ellas apoyando el análisis exploratorio realizado, y mostrando características de los datos, y una última mas compleja, mostrando alguna conclusión a la que hayan llegado tras el análisis o alguna de las consultas.
 - Visus de análisis: Deben ser de 3 tipos distintos a elegir entre: heatmaps, treemaps, scatter plot, stacked bar plot, box plot, o alguno propuesto por el alumno y validado con el ayudante.
 - Cuarta visu: Debe integrar al menos 4 variables, y debe ser de un tipo no utilizado en ninguna de las anteriores.

Criterio de evaluación

En todos los casos, evaluaremos la calidad de las visualizaciones presentadas. Algunos puntos a tener en cuenta son:

- ¿Tienen todos los ejes su rótulo?
- ¿Tiene cada visualización un título?
- ¿Es entendible la visualización sin tener que leer la explicación?
- ¿El tipo de plot elegido es adecuado para lo que se quiere visualizar?
- ¿Es una visualización interesante?
- ¿El uso del color es adecuado?
- ¿Hay un exceso o falta de elementos visuales en la visualización elegida?
- ¿La visualización es consistente con los datos?

Formato de las Consultas Entregadas

Cada consulta debe incluir:

1. Título de la consulta
2. Hipótesis tomadas
3. Código que resuelve la consulta
4. Conclusión sobre los resultados

Formato de Evaluación y Entrega

La evaluación del trabajo práctico se basará en los siguientes puntos:

1. Presentación escrita (notebook con código, salidas, documentación y análisis)
 - Link a los datos utilizados, y una breve explicación de los mismos y por qué fueron elegidos
 - Explicaciones de hallazgos y resultados.
 - Hipótesis planteadas y su justificación.
2. Evaluación en vivo
 - Presentación del trabajo en una defensa de TP
 - Elaboración de visualizaciones de los datos.
 - Respuesta a consultas sobre el conjunto de datos.
 - Preguntas conceptuales sobre el procesamiento realizado.

La entrega se realizará a través de la plataforma [Gradescope](#). Donde se deberá entregar el notebook exportado a PDF (con el output de las celdas). Tener en cuenta de incluir en la documentación del notebook link a los datos, explicaciones y análisis.

Evaluación del Informe y Código

La calificación será sobre 10 puntos.

Cada uno de los siguientes errores restará puntos:

-  No se presentan las consultas requeridas → Desaprueba
-  No se entrega informe escrito más allá del código → Desaprueba
-  Resolución ineficiente de las consultas → -2 pts
-  No se realiza una limpieza de los datos. → -2 pts
-  Análisis de datos incompleto. → -2 pts
-  Falta de trabajo para que las visualizaciones sean eficientes → -2 pts

Algunas recomendaciones

Antes de comenzar a trabajar, deben anotarse para que les sea asignado un ayudante. El plazo para esto es el jueves 12/3

Es recomendable que validen con el ayudante los datos a utilizar, y el rumbo que se le quiere dar al análisis, los ayudantes los guiarán para dimensionar correctamente el trabajo práctico y longitud esperada.