

Organización de Datos / Ciencia de Datos

Trabajo Práctico - Segunda Entrega

El TP2 estará destinado a trabajar sobre un problema de Machine Learning.

A diferencia de otros cuatrimestres, la participación en los trabajos prácticos será **opcional**, y los mismos asignarán hasta **1 punto adicional** por entrega a sumarse a la nota de cursada (en el caso del TP1) o del examen por promoción (en el caso del TP2, habiendo aprobado el promocional).

Si alguno no realizó el TP1 y quiere hacer el TP2, por favor **contactarse con nosotros** para que podamos asignarles un ayudante.

Queremos destacar que más allá de la no obligatoriedad del mismo, la cátedra considera **altamente recomendable** realizarlo ya que dará práctica y herramientas que resultarán muy valiosas a la hora de rendir los exámenes parciales.

Metodología

- El desarrollo del trabajo práctico es **opcional**.
- Cada alumno contará con un **ayudante asignado** al que podrá hacer consultas específicas sobre su trabajo.
- Para cualquier duda de la solución que están pensando, pueden pedir ayuda por **Slack** (sin publicar su idea), y el primer ayudante disponible intentará responderles.
- Existirá un canal de consultas general en Slack para dudas que puedan ser respondidas por cualquier miembro del equipo docente o incluso por otros alumnos.

Proceso de Trabajo

Para la segunda entrega, los alumnos deberán elegir un dataset (puede ser el mismo que ya trabajaron para el TP1, la elección del dataset debe ser validado y aprobado por su ayudante asignado), y realizar todo el proceso:

1. **Limpieza y EDA:** Realizar la limpieza de datos y análisis exploratorio.
2. **Definición del Problema:** Enunciar un problema a resolver con métodos de ML vistos en clase. *Es muy importante validar este punto con su ayudante antes de seguir.*
3. **Baseline:** Plantear una solución simple a utilizar como baseline.
4. **Modelado:** Implementar al menos 2 modelos, evaluar ambas soluciones y elaborar una recomendación.
5. **Feature Engineering:** Generar nuevos features útiles para mejorar las predicciones. Evaluar cada feature indicando su impacto.

6. **Búsqueda de hiperparámetros:** debe realizar este paso en todos los modelos que implemente, teniendo en cuenta los hiperparámetros principales para cada modelo.

Condiciones de los Modelos

Los modelos deben cumplir las siguientes condiciones:

Criterio	Requisito
Validación	Contar con una métrica definida y medirse en el set de validación.
Reproducibilidad	El notebook debe arrojar el mismo resultado en cada corrida.
Performance	Score en validación superior a 0,8 .
Codificación	Uso obligatorio de <i>mean encoding</i> y <i>one hot encoding</i> (al menos una vez cada uno).

Graficar y analizar para alguno de los modelos: Curva ROC (explicando selección de corte), Feature importance y Matriz de confusión.

Formato de Evaluación y Entrega

1. Presentación escrita (Notebook)

- Link a los datos utilizados y breve explicación de la elección.
- Explicaciones de hallazgos, resultados e hipótesis planteadas con su justificación.

2. Evaluación en vivo (Defensa)

- Presentación del trabajo, visualizaciones de datos y respuesta a consultas conceptuales.

Entrega: A través de **Gradescope**. Se debe entregar el notebook exportado a **PDF** (con output de celdas), incluyendo links, explicaciones y análisis.